Lenguaje de Marcas y Sistemas de Información

INDICE

Lenguajes de marcas y sistemas de gestión de información. 3

1. Unidad 1. Reconocimiento de las características de los lenguajes de marcas : 3

1.1. Concepto de lenguaje de marcas: Origen SGML 3

1.1.1. Marca 3

1.1.2. Clases de lenguajes de marcas 4

1.1.3. Características del Lenguaje de Marcas 4

1.2. Un poco de historia 6

1.2.1. El abuelo: GML (Generalized Markup Language) 6

1.2.2. El papá: SGML (Standard Generalized Markup Language) 6

1.2.3. El primogénito: HTML 7

1.2.4. Los hermanos: XML (Extensible Markup Language) y XHTML 8

1.2.5. Los hijos: SVG, XSL, XSLT, XLink, XSD, DocBook, MathML 9

1.3. Ejercicios 10

Lenguajes de marcas y sistemas de gestión de información.

1. Unidad 1. Reconocimiento de las características de los lenguajes de marcas :

Contenidos

- Concepto de lenguaje de marcas. Origen: SGML.
  - Características comunes.
  - Concepto de metalenguaje.
- Clasificación.
- Etiquetas.
- Herramientas de edición.

1.1. Concepto de lenguaje de marcas: Origen SGML

1.1.1. Marca y Lenguaje de Marcado

Una "marca" históricamente es una anotación que intenta señalar a un tipógrafo cómo debe imprimirse o prepararse un texto determinado
"Marca" en la actualidad es toda clase de códigos insertados en textos electrónicos que determinan el formato, el modo de impresión o cualquier otro proceso

Un lenguaje de marcado en los documentos electrónicos es un tipo de lenguaje que combina texto con información extra acerca del texto. Esa información extra se entremezcla con el texto primario El lenguaje de marcas más conocido en la actualidad es el HTML, que se utiliza en las páginas Web.

Ejemplo: Lenguaje de marcas HTML

```
<HTML>
  <HEAD>
    <TITLE>Mi primera pagina</TITLE>
  </HEAD>

  <BODY>
    <CENTER><H1>Mi Primera pagina</H1></CENTER>
    <HR>
    <P>Esta es mi primera pagina (chispas). Por el
    momento no se que tendra, pero dentro de poco
    pondre aqui muchas cosas interesantes.
  </BODY>
</HTML>
```

El marcado define una serie de códigos llamados **etiquetas** añadidos al texto electrónico que definen la estructura y el formato en el que tienen que aparecer. Las marcas también están formadas de texto, pero que es interpretado cuando se muestra el documento, y suelen llamarse también etiquetas.

La estructura se refiere a los elementos con que se organiza un documento (título, temas, capítulos…) y el **formato** se refiere a la presentación (tipo de fuente, negrita, cursiva, etc.)

Los lenguajes de marcas se utilizan para propósitos muy diversos como la escritura, la impresión, intercambio, presentación de pantallas, etc. Hay una gran variedad de lenguajes de marcado y son muchos incompatibles, lo que supone un problema a la hora de intercambiar documentos entre plataformas heterogéneas. Los lenguajes estándar proporcionan una manera de solucionar este problema, ya que son independientes de la aplicación y de la plataforma hardware, empleando para marcar en la mayoría de los casos código ASCII.

1.1.2. Clases de lenguajes de marcas

Existen tres clases de lenguajes de marcas, y pueden presentarse todas en un mismo documento.

- **Marcas de presentación**: estas marcas indican el **formato**-marco del texto. Su uso comienza a reducirse dado que es poco flexible, especialmente en grandes proyectos. Este tipo de marcado es útil para maquetar la presentación de un documento para su lectura, pero resulta insuficiente para el procesamiento automático de la información.
- **Marcas de procedimientos**: estas marcas se utilizan para la **presentación** del texto, interpretándose cada una en el orden que en aparecen. Por ejemplo, la marca que se agrega inmediatamente antes de un texto para que se vea en negrita: (en HTML: ****)**.** Luego debe existir la marca correspondiente que termine o cierre la negrita. (en HTML: ****)**.** Otras marcas de procedimientos pueden ser centrar texto, cambio de tamaño de fuente, cambios de estilos, etc. Algunos lenguajes de marcas de procedimiento son nroff, troff, TeX, PostScript, HTML, etc.
- **Marcas descriptivas**: También llamadas marcado descriptivo, o semántico. Aquí se utilizan las marcas para describir fragmentos de texto sin especificar cómo deben representarse. Algunos lenguajes diseñados para esto son el SGML y el XML. (Ejemplo XML: <libro>)
  En los lenguajes de marcas descriptivas el formato está separado del contenido, permitiendo flexibilidad a la hora de reformatear un texto.

1.1.3. Características del Lenguaje de Marcas

Texto plano

Una de las principales ventajas de este tipo de codificación es que puede ser interpretada directamente, dado que son archivos de texto plano.

Un documento escrito con lenguajes de marcado puede ser editado por un usuario con un sencillo editor de textos, sin perjuicio de que se puedan utilizar programas más sofisticados que faciliten el trabajo.

Al tratarse solamente de texto, los documentos son independientes de la plataforma, sistema operativo o programa con el que fueron creados. Esta fue una de las premisas de los creadores de GML en lo años 70, para no añadir restricciones innecesarias al intercambio de información. Es una de las razones fundamentales de la gran aceptación que han tenido en el pasado y del excelente futuro que se les augura.

Compacidad

Las instrucciones de marcado se entremezclan con el propio contenido en un único archivo o flujo de datos. Este es un ejemplo en diferentes lenguajes de marcas:

Ejemplos	HTML	LaTeX	Wikitexto
Título	<h1>Título</h1>	\section{Título}	== Título ==
Lista	<ul> <li>Punto 1</li> <li>Punto 2</li> <li>Punto 3</li> </ul>	\begin{itemize} \item Punto 1 \item Punto 2 \item Punto 3 \end{itemize}	* Punto 1 * Punto 2 * Punto 3
texto en **negrita**	texto	\bf{texto}	' ' ' texto ' ' '
texto en *cursiva*	texto	\it{texto}	' ' texto ' '

El código entre corchetes com *<ul>*, o con códigos *\section*, son instrucciones de marcado, también llamados etiquetas. Estas etiquetas en concreto son descriptivas de la estructura del documento, pudiendo ser su presentación visual de varias maneras. La etiqueta **i** (de ***italics***, cursiva), por el contrario, especifica que el texto se debe mostrar en cursiva, sin especificar el motivo de esta diferenciación: es una etiqueta presentacional. El texto entre estas instrucciones es el propio contenido del documento.

Facilidad de procesamiento

Las organizaciones de estándares han venido desarrollando lenguajes especializados para los tipos de documentos de comunidades o industrias concretas. Uno de los primeros fue el CALS, utilizado por las fuerzas armadas de EE.UU. para sus manuales técnicos. Otras industrias con necesidad de gran cantidad de documentación, como las de aeronáutica, telecomunicaciones, automoción o hardware, ha elaborado lenguajes adaptados a sus necesidades. Esto ha conducido a que sus manuales se editen únicamente en versión electrónica, y después se obtenga a partir de ésta las versiones impresas, en línea o en CD. Un ejemplo notable fue el caso de Sun Microsystems, empresa que optó por escribir la documentación de sus productos en SGML, ahorrando costes considerables. El responsable de aquella decisión fue Jon Bosak, que más tarde fundaría el comité del XML.

Flexibilidad

Aunque originalmente los lenguajes de marcas se idearon para documentos de texto, se han empezado a utilizar en áreas como gráficos vectoriales, servicios web, sindicación web o interfaces de usuario. Estas nuevas aplicaciones aprovechan la sencillez y potencia del lenguaje XML. Esto ha permitido que se pueda combinar varios lenguajes de marcas diferentes en un único archivo, como en el caso de XHTML+SMILy de XHTML+MathML+SVG.

1.2. Un poco de historia

Todo comenzó con la intención de **estandarizar** el formato en el que los diversos documentos se encuentran en las computadoras. A cualquiera de nosotros nos ha pasado alguna vez que alguien nos envíe, por ejemplo, un texto para revisar y no podemos verlo debido a que está hecho con un programa de texto distinto al que tenemos instalado en nuestro ordenador. O podemos verlo, pero con un aspecto bastante distinto al que quería darle su autor. En eso, seguramente, estaba pensando Charles F. Goldfab cuando en los años 70 la empresa estadounidense IBM le encargó el trabajo de "describir documentos".

1.2.1. El abuelo: GML (Generalized Markup Language)

IBM propuso un sistema de documentos que identificase a cada uno de sus elementos lógicos (títulos y subtítulos, direcciones, páginas, capítulos, párrafos, listas, etc.) con algún tipo de **etiqueta** dentro del propio documento. No se trataba de la apariencia del documento, sino de la **estructura lógica** del mismo, de modo que la visualización e impresión de dichos documentos podría ser **independiente del hardware** en particular, aunque un sistema de ese tipo requeriría algún tipo de software específico para esa visualización e impresiones. IBM desarrolló una especie de **pseudolenguaje de computadora que combina sólo texto e instrucciones de formateado**. Dicho lenguaje se llamó **"lenguaje de marcas"** e IBM lo bautizó como Lenguaje de marcas generalizado o GML (Generalized Markup Language).

1.2.2. El padre: SGML (Standard Generalized Markup Language)

```
<EMail>
     <sender>
            <person>
                   <firstname> Karen </firstname>
                   <lastname> Lemone </lastname>
            </person>
     </sender>
     <receiver>
            <person>
                   <distributionList> cs525@cs.com
     </distributionList>
            </person>
```

```
    </receiver>
    <contents>¿no es sencillo?</contents>
</EMail>
```

En la práctica, IBM **nunca llegó demasiado lejos con el GML**, pero en 1986 la Organización Internacional de Estándares **(ISO**) decidió que esa empresa tenía un buen comienzo, y presentó la publicación ISO 88879, **que definía un lenguaje de marcas** para la creación de documentos estandarizados. **ISO creó su lenguaje a partir del GML** de IBM y lo llamó Lenguaje de marcas generalizado estándar **o SGML** (Standard Generalized Markup Lenguaje).

Siguiendo con la idea de su predecesor, SGML no almacena el diseño, sino la estructura lógica de los documentos. Lo hace a través de **etiquetas o "tags**" que se incluyen entre los signos **< y > e indican cuando comienza y termina un título, una lista, etc.** El objetivo era poder asegurar electrónicamente que los documentos importantes fuesen **independientes de los formatos de archivo binario en constante cambio** (Word, WordPerfect, WordStar, etc.) o de los sistemas operativos (Windows, MacOS, UNIX, Sun, BeOS, etc.).

No se popularizó porque **SGML era muy complicado**, no estaba pensando en el usuario medio y las herramientas para la creación de SGML eran caras y no tuvieron gran aceptación.

Formalmente SGML es **metalenguaje, permite definir otros lenguajes. Es un lenguaje soporte para crear lenguajes especializados, que tiene una estructura común, unas reglas de etiquetado. Se concreta el lenguaje mediante diccionarios y esquemas: Etiquetas para usos concretos, reglas de composición y condiciones sobre contenido. Para que el lenguaje sea correcto hay una doble validación: el documento debe estar bien formado y debe ser válido.**

1.2.3. El primogénito: HTML

```
<HTML>
  <HEAD>
    <TITLE>Mi primera pagina</TITLE>
  </HEAD>

  <BODY>
    <CENTER><H1>Mi Primera pagina</H1></CENTER>
    <HR>
    <P>Esta es mi primera pagina.
  </BODY>
</HTML>
```

Pero en 1990 Tim Berners-Lee, del Laboratorio Europeo de Física de Partículas tomó el SGML y lo combinó con la idea de que en un documento **se pudiese crear un "enlace"** para acceder a otro (la idea ya existía desde los ochentas y se llamaba "hipertexto") **creando el lenguaje HTML** (de Lenguaje de marcas hipertextual o HyperText Markup Language), base de la World Wide Web.

Al hacer tan sencillo al HTML, Berners-Lee colaboró enormemente en la popularización de la Web. Fué tal el crecimiento que decidió crear el World Wide Web Consortium o W3C, encargado del desarrollo de lenguajes y estándares para la Web. Lo que propone el W3C se convierte, tiempo después, en estándar del sector.

1.2.4. Los hermanos: XML (Extensible Markup Language) y XHTML

Con el paso del tiempo se fue viendo que **HTML** estaba pensado para mostrarse en un navegador Web, pero **no para impresión o tareas de diseño**. Situaciones en las que aparecían márgenes de páginas, formatos de papel, párrafos especiales, encabezados o pies de página, índices, tablas o referencias cruzadas eran manejadas pobremente por HTML, incluso usando hojas de estilo (CSS).

También se observó que **las etiquetas son limitadas y poco flexibles,** por lo que causan problemas al intentar incluir gráficos vectoriales u hojas de cálculo. **Tampoco puede mostrar contenidos dinámicos** y debe recurrir a lenguajes del tipo ASP, PHP o similar. Por último, y pese a los intentos de sus comienzos, la estructura y el diseño se mezclan, lo que causa problemas a la hora de intentar navegar páginas con diversas tecnologías (terminales Braille o UNIX, teléfonos móviles, WebTV, navegadores de texto o de voz, etc.).

Entonces se decidió volver a la fuente de todos estos lenguajes de marcas: SGML. Pero SGML seguía siendo complicado para los usos generales que la Web necesitaba, así que **se decidió escribir desde cero un nuevo lenguaje de marcas, también basado el SGML pero con más posibilidades de ampliación que el HTML**. Así, en 1998, el Consorcio W3 y empresas como Microsoft **decidieron implementar el lenguaje XML** (Lenguaje de marcas extensible o Extensible Markup Language) como sucesor del HTML.

Ejemplo XML

```
<?xml version="1.0" encoding='iso-8859-1' ?>
<micasa>
     <habitacion id='comedor'>
             <mueble>aparador</mueble>
             <mueble>sofá</mueble> <puerta a='balcón' />
     </habitacion>
</micasa>
```

XML es una versión más sencilla de SGML y más fácil de aplicar, diseñada para hacer frente a los problemas de compatibilidad y adaptabilidad de las nuevas tecnologías a Internet.

Una diferencia fundamental de XML con su predecesor es que en este lenguaje **no hay elementos predefinidos.** Cada usuario (o grupo de usuarios) puede crear su propio lenguaje para el formato de datos y documentos, su propio vocabulario, según sus necesidades, siguiendo ciertas reglas. Elementos como <titulo>, <autor>,

<sexo>, <fecha_nacimiento>, <pregunta>, <respuesta>, <nombre>, <apellido> o <precio> son perfectamente válidos en XML.

XML es como SGML un Metalenguaje.

La otra gran diferencia con HTML es que XML es puramente estructural. No incluye ninguna información relativa al diseño. Sólo almacena datos y estructura. Para dar formato a esos datos para cada finalidad (web, impresión, proyección, Braille, etc.) se debe usar un lenguaje de diseño, como CSS o XSL.

Pero como este lenguaje también resultaba complicado para los usuarios comunes, y también se encontró con que muchos navegadores tenían problemas de compatibilidad con él, se decidió crear un "lenguaje de transición" que permitiera a los usuarios acercarse al nuevo lenguaje y que al mismo tiempo ofreciera muchas de las posibilidades del HTML.

Así nació el XHTML, una reformularización del HTML basada en XML.

Ejemplo XHTML

```
<?xml version="1.0" encoding="UTF-8"?>
<!DOCTYPE html PUBLIC "-//W3C//DTD XHTML 1.0 Strict//EN"
"http://www.w3.org/TR/xhtml1/DTD/xhtml1-strict.dtd">
<html xmlns="http://www.w3.org/1999/xhtml" xml:lang="es" lang="es">
      <head>
              <title>Titulo de la pagina</title>
      </head>
      <body>
              <p>Primer documento XHTML, es decir un, Hola mundo</p>
      </body>
</html>
```

XHTML tiene varias diferencias con el HTML, pero es compatible con éste. Además es posible ver las páginas creadas con él en los navegadores que antes nos permitían ver páginas HTML.

1.2.5. Los hijos: SVG, XSL, XSLT, XLink, XSD, DocBook, MathML

Pero XML no sólo es un lenguaje de marcas, sino un metalenguaje, un lenguaje que permite crear otros lenguajes (de ahí la palabra eXtensible de la sigla). He aquí algunos de ellos:

XSL es un lenguaje para utilizar hojas de estilo e intenta superar las restricciones que tienen las hojas de estilo en cascada o CSS. Desgraciadamente, aún no está suficientemente soportado por los navegadores que hay en el mercado, aunque esto se va modificando de a poco. El XSL es un conjunto de tres partes: XSL Transformations (XSLT o Transformaciones XSL): un lenguaje para transformar documentos XML, el

XML Path Language (XPath), un lenguaje de expresión usado por XSLT para acceder o referirse a partes de un documento XML. (XPath también es usado por la especificación XML Linking). La terecera parte es XSL Formatting Objects: un vocabulario XML para la especificación de formateo de semánticas. Una hoja de estilo XSL especifica la presentación de una clase de documentos XML describiendo cómo una instancia de la clase es transformada en un documento XML que usa el vocabulario de formateo.
El XSL es desarrollado por el grupo de trabajo XSL del Consorcio W3, quienes están trabajando para liberar la próxima versión del XSL.

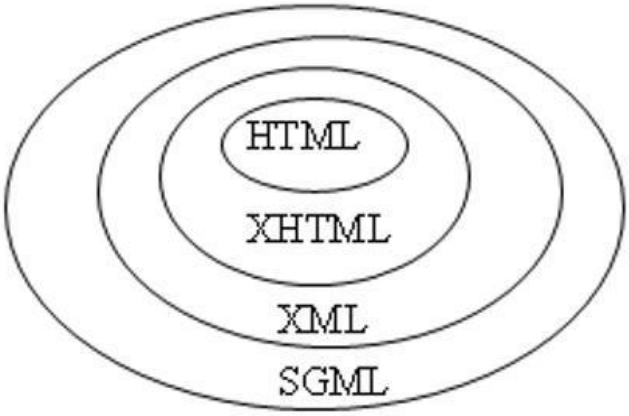

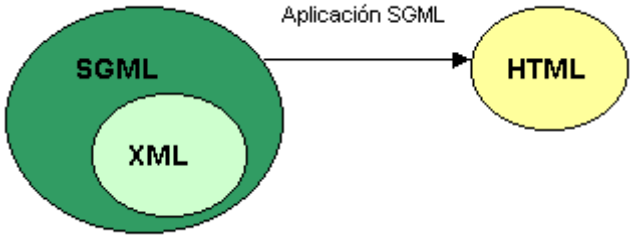

1.3. Ejercicios

1. ¿Que es el lenguaje de marcas?
2. ¿Por qué surgió el lenguaje de marcas?
3. ¿Cuál fue el primer lenguaje de marcas?
4. Selecciona los lenguajes de marcas que conoces y busca diferencias entre ellos.
5. Define Metalenguaje con tus propias palabras
6. Que es W3C
7. Acceder a W3C y localizar:
    a. Historia y organización
    b. Estándares originales html, css, xml
    c. Traducciones
    d. Validadotes en línea
8. XML es un metalenguaje, un lenguaje que permite crear otros lenguajes. Alguno de ellos son: SVG, XSL, XSLT, XLink, XSD, DocBook, MathML. Busca información sobre ellos.